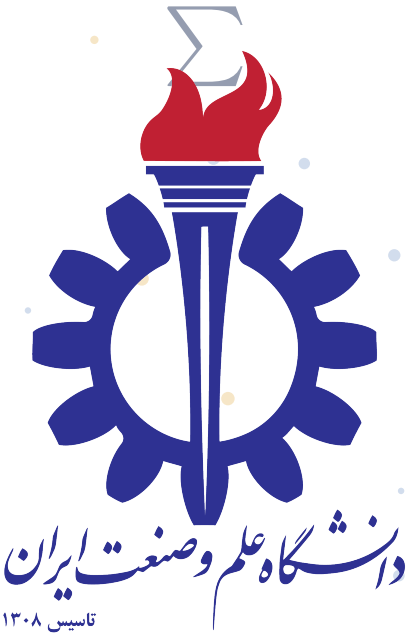


درس داده‌کاوی، مینی‌پروژه ۲

درخت تصمیم

بیش‌برازش و ارزیابی مدل

اساتید درس	دکتر غیور باغبانی و دکتر سپهر
طراح	فاطمه یوسفی
نیم‌سال تحصیلی	نیم‌سال اول ۱۴۰۵-۱۴۰۶
مباحث	رده‌بندی پایه، بیش‌برازش و ارزیابی مدل
تاریخ انتشار	۱۴۰۵/۰۷/۲۶
ددلاین تحویل	۱۴۰۵/۰۸/۰۹
نمره	از ۱۰۰

۱ قوانین کلی

- کار باید به‌صورت انفرادی انجام شود. کدزنی از دیگران یا استفاده از کد آماده‌ی دانشجویان دیگر، بدون ارجاع، تقلب محسوب می‌شود.
- استفاده از ابزارهای هوش مصنوعی (مانند ChatGPT و مشابه آن) ممنوع نیست، به شرط آن‌که میزان و نحوه‌ی استفاده با جزئیات کامل در گزارش ذکر شود. صرف کپی‌کردن خروجی یک ابزار بدون درک و توضیح، تخلف محسوب می‌شود؛ خیلی از سوال‌های این پروژه فقط با اجرای واقعی کد روی داده‌ی خودتان جواب دارند، نه با یک پاسخ عمومی.
- مهلت تأخیر مجاز در طول ترم محدود است (طبق اطلاعیه‌ی رسمی گروه)؛ برای همین از همان ابتدای انتشار پروژه برای تحویل آن برنامه‌ریزی کنید.
- تمدید فقط در شرایط خاص و با هماهنگی تیم دستیار امکان‌پذیر است.
- نمره‌ی نهایی بر اساس سه مورد تعیین می‌شود: درستی و کامل‌بودن کد، کیفیت و شفافیت گزارش، و تعهد به ددلاین اعلام‌شده.

تبصره: در کل ترم ده روز تأخیر مجاز برای دریافت تمام مینی‌پروژه‌ها در اختیار دارید، اما از این سهمیه حداکثر سه روز را می‌توان برای همین یک مینی‌پروژه استفاده کرد. زمان‌بندی این پروژه طوری بسته شده که عملاً جایی برای تأخیر باقی نمی‌ماند؛ برای همین از همان روز اول برای تحویل آن برنامه‌ریزی کنید و درخواست تمدید را به لحظات پایانی موکول نکنید. تمدید نیز فقط در شرایط خاص و استثنایی، و با هماهنگی تیم دستیار، امکان‌پذیر است.

۲ نحوه تحویل و فرمت‌بندی فایل‌ها

تحویل نهایی شامل دو بخش است: کدها (نوت‌بوک یا اسکریپت) و گزارش. هر دو باید در قالب یک فایل زیپ کنار هم قرار بگیرند.

۱.۲ فرمت نام‌گذاری فایل

برای اینکه پیدا کردن و دسته‌بندی تعداد زیادی فایل ساده باشد، همه دانشجویان باید از این الگوی زیر پیروی کنند:

```
[StudentID]_[LastName]_MP2.zip
```

مثال: `9912345_Entezari_MP2.zip`

داخل زیپ هم همین الگو را دنبال کنید:

- `9912345_Entezari_MP2_Report.pdf`
- `9912345_Entezari_MP2_Code.ipynb` (یا پوشه‌ای از فایل‌های کد، اگر پروژه بیشتر از یک فایل نیاز دارد)

فایلی که این الگو را رعایت نکند، هیچ نمره‌ای به آن تعلق نمی‌گیرد.

۲.۲ محتوای گزارش

- ✓ یک صفحه ابتدایی برای معرفی (لوگوی دانشگاه، نام درس، شماره دانشجویی و نام خود دانشجو)
- ✓ عکس از ورودی‌ها و خروجی‌ها و روند کلی کار، از جمله نمودارهای خواسته‌شده در گام‌های مختلف
- ✓ توضیح ساده و قابل‌فهم برای هر بخش از کد: چرا این کار انجام شده و چطور به نتیجه رسیده‌اید
- ✓ اگر از روش یا تکنیک خاصی استفاده کردید، حتماً ذکرش کنید
- ✓ مشکلاتی که حین کار با آن‌ها مواجه شدید، به همراه راه‌حلی که پیدا کردید
- ✓ میزان و نحوه دقیق استفاده از LLMها (اگر استفاده شده)

۳ مینی‌پروژه ۲: درخت تصمیم، بیش‌برازش و ارزیابی مدل

۱.۳ بخش اول: مجموعه‌داده و برچسب هدف

در این پروژه از روی داده‌ی واقعی یک شرکت تاکسی‌اینترنتی بررسی می‌کنید که آیا می‌شود، فقط با اطلاعاتی که در لحظه‌ی ثبت درخواست موجود است، پیش‌بینی کرد که راننده ظرف ۵ دقیقه به مسافر می‌رسد یا نه.

۱. RideAustin یک تاکسی‌اینترنتی غیرانتفاعی بود که در شهر آستین آمریکا فعالیت می‌کرد. داده‌ی این پروژه از سفرهای واقعی همین سرویس است و نسخه‌ی عمومی‌اش با مجوز باز CC0 منتشر شده.

۲. فایلی که در اختیار شما قرار گرفته `austin_commute_raw.csv` نام دارد: نمونه‌ای تصادفی از ۱۵۰٬۰۰۰ سفر واقعی با ۳۱ ستون (نزدیک به ۵۳ مگابایت). اسکریپت `prepare_dataset.py` که نحوه‌ی ساختن این نمونه را نشان می‌دهد نیز صرفاً برای شفافیت پیوست شده.

۳. این داده را یک سازمان با فرمت یکدست وارد نکرده؛ مستقیم از سامانه‌ی داخلی RideAustin صادر شده و هنوز همان حالت خامش را دارد. فایل عمداً پاک‌سازی نشده است.

ستون‌های فایل. هر سفر یک `RIDE_ID` دارد و پنج مرحله‌ی زمانی‌اش به‌ترتیب ثبت شده: `created_date` (ثبت درخواست)، `dispatched_on` (ارسال درخواست به یک راننده‌ی مشخص)، `driver_accepted_on` (پذیرش راننده)، `driver_reached_on` (رسیدن راننده به مسافر) و `completed_on/started_on` (شروع و پایان سفر). `dispatched_on` بر خلاف بقیه، به وقت UTC ثبت شده، نه وقت محلی آستین.
موقعیت مسافر در `start_location_lat/long` است و موقعیت راننده در لحظه‌ی ارسال درخواست در `dispatch_location_lat/long`. نوع خودروی درخواستی `requested_car_category` است و خودروی واقعاً اعزام‌شده در `make`، `model`، `year` و `color`. نرخ کرایه در `base_fare`، `rate_per_mile` و `rate_per_minute` است و ضریب سورژ در `surge_factor`. امتیاز راننده و مسافر در `driver_rating` و `rider_rating` است و شناسه‌ی ناشناس‌شده‌ی راننده، مسافر و خودرو در `driver_id`، `rider_id` و `car_id`. ستون `status` دو مقدار دارد، DISPATCHED و DECLINED. سامانه‌ی خود RideAustin هم دو برآورد از پیش دارد: `driving_distance_to_rider`، `driving_time_to_rider` و `esimtated_time_arrive` (همین املای غیررایج در داده‌ی اصلی هم همین‌طور است، تغییرش ندهید).
دو ستون آخر، `pickup_zone` و `downtown_km`، را خودمان ساخته‌ایم: اولی محل سوارشدن مسافر را به یکی از پنج ناحیه‌ی قطب‌نمایی نسبت به مرکز آستین می‌برد، دومی فاصله تا همان مرکز را به کیلومتر می‌دهد. مثل مینی‌پروژه‌ی اول، این تقسیم‌بندی رسمی نیست.

هیچ ستونی به اسم «برچسب» یا «جواب» در فایل نیست؛ آن را خودتان از روی `driver_reached_on` و `dispatched_on` می‌سازید، همان کاری که در گام اول خواسته شده.

۲.۳ بخش دوم: شرح مسئله

۱.۲.۳ گام اول: پیش‌پردازش و پرهیز از نشت داده (۱۵ نمره)

۱. زمان‌های `dispatched_on` (UTC) و `driver_reached_on` (وقت محلی آستین) را به یک مبنای مشترک ببرید و ستون هدف `on_time` را بسازید: یک اگر فاصله‌شان حداکثر ۵ دقیقه باشد، وگرنه صفر. سهم هر کلاس را گزارش دهید.

۲. ستون‌های `status`، `requested_car_category`، `make`، `model`، `color` و `year` را از شکل `b'...'` (رونوشت خام رشته‌ی بایتی پایتون) باز کنید؛ `year` را هم به عدد صحیح تبدیل کنید. سپس ستون `make` را نرمال‌سازی کنید (فاصله‌ی اضافه، املای ناهمسان مثل Chevrolet/Chevy) و تعداد مقادیر یکتا را قبل و بعد مقایسه کنید.

۳. درصد مقدار گمشده‌ی هر ستون را حساب کنید و مقادیر ستون `dispatch_location_lat` را با `dispatch_location_long` مقایسه کنید؛ آیا این دو واقعاً دو کمیت متفاوت‌اند؟

۴. فهرست کنید کدام ستون‌ها اطلاعاتی را فاش می‌کنند که در لحظه‌ی `dispatched_on` هنوز وجود نداشته (نشت داده): حداقل `driver_reached_on`، `started_on`، `completed_on`، `driving_time_to_rider` و `esimtated_time_arrive` را بررسی کنید و برای هرکدام یک جمله بنویسید که چرا نباید مستقیماً ویژگی مدل باشند. در پایان، فهرست نهایی ویژگی‌های مجاز برای مدل‌سازی را اعلام کنید.

۲.۲.۳ گام دوم: دسته‌بندی پایه (۲۰ نمره)

۱. داده را به سه بخش آموزش، اعتبارسنجی و آزمون (مثلاً به نسبت ۷۰/۱۵/۱۵) تقسیم کنید، به‌طوری که نسبت دو کلاس `on_time` در هر سه بخش حفظ شود.

۲. دقت یک مدل پایه که همیشه کلاس اکثریت را پیش‌بینی می‌کند (majority baseline) را روی هر سه بخش حساب کنید. از این پس، هر مدلی که بسازید باید با این عدد مقایسه شود.

۳. با ویژگی‌های مجازی که در گام اول مشخص کردید، یک درخت تصمیم با تنظیمات پیش‌فرض (بدون محدودیت عمق) آموزش دهید. دقت روی مجموعه‌ی آموزش و اعتبارسنجی را گزارش دهید.

۴. برای گره‌ی ریشه‌ی همین درخت، معیار Gini یا Entropy را برای تقسیمی که خود مدل انتخاب کرده، با دست و با فرمول (نه با فراخوانی مستقیم تابع کتابخانه) حساب کنید و نتیجه را با مقداری که کتابخانه گزارش می‌دهد مقایسه کنید.

۳.۲.۳ گام سوم: بیش‌برازش (۲۵ نمره)

۱. پنج درخت تصمیم با پنج مقدار متفاوت برای عمق (مثلاً ۲، ۴، ۸، ۱۶ و بدون محدودیت) آموزش دهید و دقت آموزش/اعتبارسنجی هرکدام را در یک جدول کنار هم بگذارید.

۲. یک نمودار بکشید: محور افقی عمق درخت، محور عمودی دقت، با دو خط جدا برای آموزش و اعتبارسنجی. نقطه‌ی شروع بیش‌برازش را روی همین نمودار مشخص کنید.

۳. یکی از این پنج مدل را به‌عنوان مدل نهایی انتخاب کنید و دلیل انتخاب را بنویسید (دلیل «بالاترین دقت روی داده‌ی آموزش» پذیرفته نیست)، و در یک پاراگراف بگویید موازنه‌ی variance/bias دقیقاً کجای این نمودار خودش را نشان می‌دهد.

۴.۲.۳ گام چهارم: ارزیابی مدل (۲۰ نمره)

۱. مدل منتخب گام سوم را فقط یک‌بار روی مجموعه‌ی آزمون اجرا کنید و ماتریس درهم‌ریختگی (confusion matrix) را رسم کنید.

۲. Accuracy، Precision، Recall و F1 را برای هر دو کلاس حساب کنید.

۳. مشخص کنید مدل بیشتر مرتکب خطای مثبت کاذب می‌شود یا منفی کاذب، و توضیح دهید این نوع خطا برای کاربری که می‌خواهد بین اسنپ و مترو انتخاب کند چه پیامد عملی دارد.

۵.۲.۳ گام پنجم: ارزیابی جغرافیایی (۱۵ نمره)

۱. Accuracy و F1 مدل منتخب را به تفکیک پنج مقدار ستون `pickup_zone` حساب کنید.

۲. آیا عملکرد مدل در ناحیه‌ی «Downtown» با سایر نواحی تفاوت معناداری دارد؟ یک فرضیه برای دلیل این تفاوت پیشنهاد دهید و توضیح دهید چرا یک عدد Accuracy کلی می‌تواند چنین تفاوتی را پنهان کند.

۳. یادآوری کنید که `pickup_zone` و `downtown_km` تقسیم‌بندی رسمی RideAustin نیستند و این محدودیت را در تفسیر نتیجه در نظر بگیرید.

۶.۲.۳ گام ششم: تصمیم نهایی (۵ نمره)

با توجه به دقت و Recall مدل نهایی و تفاوتی که در گام پنجم بین نواحی جغرافیایی دیدید، آیا این مدل برای این‌که به‌جای مترو، سفر با اسنپ را به یک کاربر واقعی پیشنهاد دهد، کافی است؟ در یک یا دو پاراگراف مستدل، با ارجاع مستقیم به اعدادی که خودتان در گام‌های قبل به دست آوردید، پاسخ دهید.